TP3 · RedBaires: difusión de rumores y evaluación de contramedidas

Parte A: modelo conceptual y modelo de datos

Grupo 2
Integrantes: Yasmin Ohana, Julia Sexe y Santiago Minoyetti Esmerode
Fecha de entrega: 03/10/2026

1 Objetivo **2**
1.1 Definición del problema 2
1.2 Alcance 2
2 Modelo conceptual **3**
2.1 Variables de decisión 3
2.2 Variables de referencia 3
2.3 Variables de estado 3
2.4 Plan de cuadros (conceptual) 4
2.5 Plan de experimentación (conceptual) 4
2.6 Diagrama de proceso 4
2.7 Eventos destacados y lógicas 5
2.8 Variables aleatorias, Parámetros y relación entre ellos 7
2.9 Elementos del simulador 7
3 Modelo de Datos **8**
3.1 Tabla diccionario 8
3.2 Análisis y cuantificación de variables 8
3.3 Análisis estadístico 9
3.4 Relación entre variables 9
3.5 Verificación integral contra los datos 10
3.6 Evaluación a priori 10
4 Bibliografía, referencias y Anexos **12**
4.1 Bibliografía 12
4.2 Referencias 12
4.3 Descripción teórica de temas que exceden el curso 12
Anexos **13**
Anexo A. Descripción teórica 13
Anexo B. Cota de consumo 13
Anexo C. Limpieza de los datos 13
Anexo D. Ajustes de distribuciones 14
Anexo E. Parámetros de Finanzas 15
Anexo F. Reproducibilidad 15

1 Objetivo

Determinar qué combinación e intensidad de moderación, fricción a los reenvíos y degradación de alcance permite contener la difusión de contenido nocivo en RedBaires, considerando en conjunto la exposición nociva evitada, los costos asociados y el impacto sobre la actividad legítima de la plataforma. Para ello se construye un modelo de simulación de eventos discretos que permite ensayar cada alternativa antes de aplicarla sobre los 19,4 millones de usuarios activos mensuales.

1.1 Definición del problema

RedBaires factura por impresiones, de modo que todo lo que circula, incluido el contenido nocivo, genera ingreso. Un rumor se propaga por reenvíos: cada reenvío origina en promedio una cantidad de reenvíos nuevos y, mientras ese factor de multiplicación se mantenga por debajo de 1, la cascada se extingue sola. El tamaño de las cascadas es extremo: en la muestra entregada el 40,4% tiene un único evento y el 2,36% llega a 100 o más. La moderación llega con demora (nunca antes de 90 minutos desde el marcado, con una mediana de 140 min) y mientras tanto la pieza sigue propagándose.

El Directorio evalúa tres palancas: ampliar la moderación (más moderadores o un clasificador mejor), poner fricción a los reenvíos y degradar el alcance de las cuentas de mayor audiencia o de las redes coordinadas. Ninguna es gratis ya que todas tienen costo directo y recortan también la actividad legítima de la que vive la plataforma.

Problema: RedBaires no sabe cómo evolucionará una cascada de contenido nocivo ni qué efecto y costo tendrá cada medida en cada intensidad, y enfrenta un trade-off entre contención, costo e impacto sobre la actividad legítima.

1.2 Alcance

El modelo representa la aparición de piezas de contenido, su propagación por reenvíos, la evaluación automática de Centinela, la moderación humana y las tres palancas. Queda fuera la verificación de veracidad, los usuarios individuales y la red de seguidores, la competencia entre rumores por la atención, la adaptación de los atacantes y las consecuencias externas (medios, reguladores, otras empresas); estas últimas entran solo como parámetros económicos de Finanzas. El horizonte es de 30 días de operación continua (720 horas, la base mensual de los costos), con un período de calentamiento que se fija en la parte C. La Tabla 1 resume las simplificaciones y su justificación.

Tabla 1. Simplificaciones del modelo.

#	Simplificación	Justificación
S1	No se modela la veracidad: nociva = pieza con tema DISARM; legítima = tema orgánico (ORG).	Se supone que topic_code es la clasificación temática de la pieza y no la salida de Centinela, que es moderation_flag.
S2	No hay usuarios ni red de seguidores; la cuenta es atributo del reenvío, no entidad.	El encargo excluye modelar usuarios individuales; además, el nivel de quien reenvía no depende del de su padre (p = 0,21), así que puede sortearse sin red.
S3	Contenido nocivo y legítimo comparten la estructura de difusión; difieren en el atributo nociva.	Factor de nociva sobre los hijos: 0,988 (p = 0,38).
S4	Una entidad por pieza, que guarda su potencial pendiente por generación y fase y tiene un único reenvío programado (sección 2.7); cada reenvío es un evento de la pieza.	El encargo exige que el consumo no crezca con el tamaño de la cascada. No hace falta guardar cada rama: el nivel del hijo no depende del padre, y la generación y los tiempos quedan en el potencial (validación en la sección 3.5).
S5	Centinela evalúa cada aparición, sin demora ni capacidad; el primer marcado abre un único caso por pieza.	Que evalúa cada aparición lo muestran los datos: el 49,3 % de las piezas tiene alguna aparición marcada y solo el 21,2 % de las semillas. Un caso por pieza es un supuesto operativo: la remoción actúa sobre la pieza entera y la fila queda acotada.
S6	Fila FIFO; la indulgencia con cuentas verificadas se representa en la probabilidad de remoción, no en el orden.	El memo describe un sesgo en la decisión; no hay datos sobre el orden de atención.
S7	La remoción corta los reenvíos posteriores y no modifica lo ya ocurrido.	Según el memo, «una pieza removida deja de generar nuevas exposiciones».
S8	Las piezas no interactúan y la audiencia no se agota: la cascada se apaga por la edad.	Que no interactúen ni agoten la audiencia es una simplificación de alcance (no hay usuarios ni red). La extinción por edad sí sale de los datos: la media de hijos cae a la mitad cada 1,02 vidas medias (sección 3.4).
S9	La coordinación no se conoce: la señal de campaña C2 se usa como detección imperfecta, nunca como verdad.	En piezas C2 el 38,7 % de los eventos son de cuentas de menos de 90 días (resto: 18,8 %).
S10	Las decisiones reales se resumen en seis variables controlables.	Nivel de detalle mínimo que responde las preguntas de la Dirección.
S11	El puntaje de nocividad no se modela: Centinela marca cada aparición en forma independiente, con probabilidad según nociva y C.	Sobreestima un poco la detección por pieza: 53,6 % de piezas marcadas contra 49,3 % observado. Su efecto sobre el marcado y la remoción queda absorbido por nociva y C.

2 Modelo conceptual

2.1 Variables de decisión

Tabla 2. Variables de decisión. Rangos de M, U y F tomados de Finanzas.

VD	Definición	Tipo	Rango	Situación actual
M	Moderadores por turno (cobertura 24/7; simplificación: la misma dotación en los tres turnos)	Entera	1 a 12	1
C	Configuración de Centinela: par (precisión, recall) por aparición, que L1 traduce en las probabilidades de marcar una aparición nociva y una legítima	Categórica	C = 0: (0,57; 0,34), medida C = 1: (0,72; 0,63), capex 250.000 USD C = 2: (0,95; 0,90), capex 900.000 USD	C = 0
U	Umbral de fricción: reenvíos acumulados de la pieza a partir de los cuales se activa	Entera	1 a 20	Sin fricción
F	Intensidad de la fricción: reducción del alcance tras el umbral, implementada como la fracción de reenvíos posteriores que se impiden	Real	0 a 0,9	0
D	Alcance de la degradación: cuentas cuyo alcance se reduce (las coordinadas, a través de la señal imperfecta C2)	Categórica	Ninguna, mega, señaladas por C2, mega y señaladas por C2	Ninguna
δ	Intensidad de la degradación: reducción del alcance efectivo de las cuentas degradadas, que se traslada a sus impresiones y a sus reenvíos	Real	0 a 0,9	0

U cuenta el total de reenvíos de la pieza, no los saltos desde el original ni los reenvíos por usuario: es el criterio más simple de medir y frena tanto las cascadas largas como las anchas. El efecto de la degradación nunca se aplicó y Finanzas solo da su costo, por lo que δ se trata como variable de decisión con rango propio y su efecto se estudia por sensibilidad. C se expresa siempre por aparición. Los valores declarados por Finanzas (0,72; 0,63) quedan fuera de los intervalos de confianza del 95 % de lo medido (precisión de 0,52 a 0,62 y recall de 0,32 a 0,35, remuestreando cascadas completas), así que la diferencia no es error muestral; la situación actual usa lo medido, que es lo que reproduce los datos. C = 1 lleva el clasificador al desempeño declarado y C = 2 al máximo del rango de Finanzas, con el capex creciendo.

2.2 Variables de referencia

Tabla 3. Variables de referencia. IN e IL suman las impresiones de E1 y E2; CFP suma en E4.

VR	Definición y medición	Unidad	Mejor si
IN	Impresiones de piezas nocivas acumuladas durante los 30 días de medición (después del calentamiento)	impresiones/mes	Menor
IL	Impresiones de piezas legítimas acumuladas durante los 30 días de medición. ΔIL = IL(situación actual) − IL(alternativa), con números aleatorios comunes	impresiones/mes	Mayor
CFP	Costo reputacional por falsos positivos: 1,5 USD por cada pieza legítima removida	USD/mes	Menor

Contraposición. IN se opone a IL porque la fricción y la degradación frenan cualquier pieza: el umbral de reenvíos no distingue qué se está reenviando. IN se opone a CFP porque un Centinela más sensible y más moderadores llevan a revisión más piezas nocivas, pero también más legítimas, y cada remoción errónea cuesta reputación. El costo de configuración CF se conoce al fijar las VD y no es una VR: 15.840 USD por mes por puesto de moderador, capex y opex del clasificador y 120 USD por cuenta mega degradada y día (parámetro NDEG: 231 cuentas mega distintas en la muestra, cota inferior). El costo por caso de Finanzas (0,12 USD) equivale al tiempo de moderador ya pagado en CF (sección 3.6), por lo que no se suma a CFP. La evaluación económica (fuera del simulador) combina CD = CF + CFP con el valor de las impresiones legítimas perdidas y el costo social de las nocivas. Indicadores complementarios: reenvíos totales, tamaño y duración de las cascadas, demora entre marcado y remoción y falsos positivos.

2.3 Variables de estado

Tabla 4. Variables de estado. Todas se actualizan en los eventos que las modifican (Tabla 6), nunca por un reloj periódico.

VE	Describe	Se actualiza en
QM	Casos esperando en la fila de moderación	E3 (+1 si no hay moderador libre) y E4 (−1 si hay espera)
BM	Moderadores revisando un caso	E3 (+1) y E4 (−1 si la fila está vacía)
UM	% de ocupación de los moderadores: UM = BM / M × 100. Su promedio temporal es la utilización del recurso	Cada vez que cambia BM (E3 y E4)
PA	Piezas activas (con un reenvío pendiente)	E1 (+1); E1, E2 y E4 (−1 al terminar o ser removida)

VE	Describe	Se actualiza en
R_i	Reenvíos acumulados de la pieza i; estado propio de cada pieza, que activa la fricción	E1 (se inicia en 0) y E2

2.4 Plan de cuadros (conceptual)

La Figura 1 muestra la forma de los seis gráficos de resultados (G1 a G6). G1 compara la distribución de tamaños simulada con la observada (condición de aceptación que fija la Dirección). G2 muestra, para cada VD, dónde se aplana su efecto sobre IN, con intervalos de confianza del 95 %. G3 es la frontera eficiente entre IN y ΔIL: cada punto es una configuración y las que quedan por encima de la curva están dominadas. G4 compara el beneficio por peso invertido de cada palanca en los tres escenarios. G5 responde «bajo qué condiciones una medida cara se vuelve imprescindible»: indica qué palanca conviene según el costo social de una impresión nociva y la escala de m. G6 contrasta la ocupación UM y la espera en la fila contra la fórmula M/M/c de la evaluación a priori.

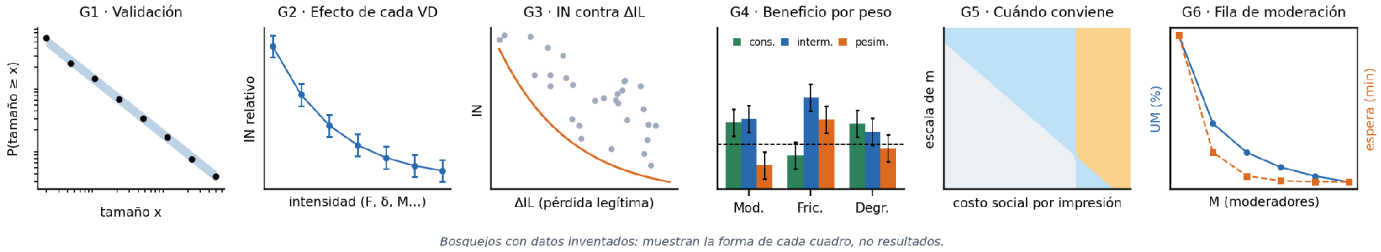


Figura 1. Bosquejos de los seis gráficos de resultados.

2.5 Plan de experimentación (conceptual)

La Tabla 5 ordena la experimentación en seis etapas; cada una usa los resultados de la anterior.

Tabla 5. Etapas de la experimentación.

Etapa	Qué se corre	Pregunta que responde
1. Situación actual	Configuración actual, escenario conservador; cálculo de N réplicas para la precisión pedida	¿El modelo reproduce las cascadas observadas? (G1)
2. Una palanca por vez	Barrido de cada VD en su rango, con las demás en la situación actual	¿Conviene cada medida y en qué intensidad? (G2, G6)
3. Combinaciones	Diseño factorial con las dos o tres mejores intensidades de cada palanca	¿Las palancas se suman o se pisan? (G3, G4)
4. Escenarios	Configuraciones finalistas en los tres escenarios	¿La conclusión resiste a los escenarios? (G4)
5. Supuestos sin datos	Nueva simulación de las finalistas variando TREV, PREM, ESC y NDEG en sus rangos	¿La recomendación depende de lo que no se midió?
6. Sensibilidad económica	Recálculo de la evaluación económica sobre los rangos de Finanzas, sin volver a simular	¿Cuándo una medida cara se vuelve imprescindible? (G5)

Escenarios. Se diferencian en cuán cerca de 1 está el factor de multiplicación m, que decide si un rumor se apaga o escapa. Conservador: parámetros estimados de la muestra (m = 0,78 hijos por reenvío). Intermedio: todas las medias de hijos multiplicadas por 1,15 (m = 0,90). Pesimista: medias multiplicadas por 1,24 (m = 0,97) y, dentro del flujo normal de siembras, un episodio como el del 14 de junio: una pieza nociva con señal C2 sembrada en una cuenta mega un sábado al mediodía. Ese episodio es el contraste del modelo con el caso real que motiva el encargo.

Criterios de decisión. Una medida conviene si el intervalo de confianza de su beneficio neto queda entero por encima de 0 en el escenario intermedio; entre las que convienen, se ordenan por beneficio por peso invertido. Se recomienda la configuración no dominada en los tres escenarios y, si hay conflicto, pesa más el pesimista, porque el Directorio fijó como prioridad que no se repita el 14 de junio. Todas las comparaciones usan números aleatorios comunes (misma siembra en cada configuración), que reducen la varianza de las diferencias (LAW, p. 588). Con M = 1 la fila está al borde de la saturación (sección 3.6) y no llega a un régimen estacionario dentro de un mes; por eso cada réplica se trata como terminante: 30 días que arrancan con la fila vacía, descartando el primer día para que haya piezas activas.

2.6 Diagrama de proceso

La Figura 2 descompone la actividad A0 en dos procesos acoplados: la propagación (A1 y A2) y la moderación (A3 y A4).

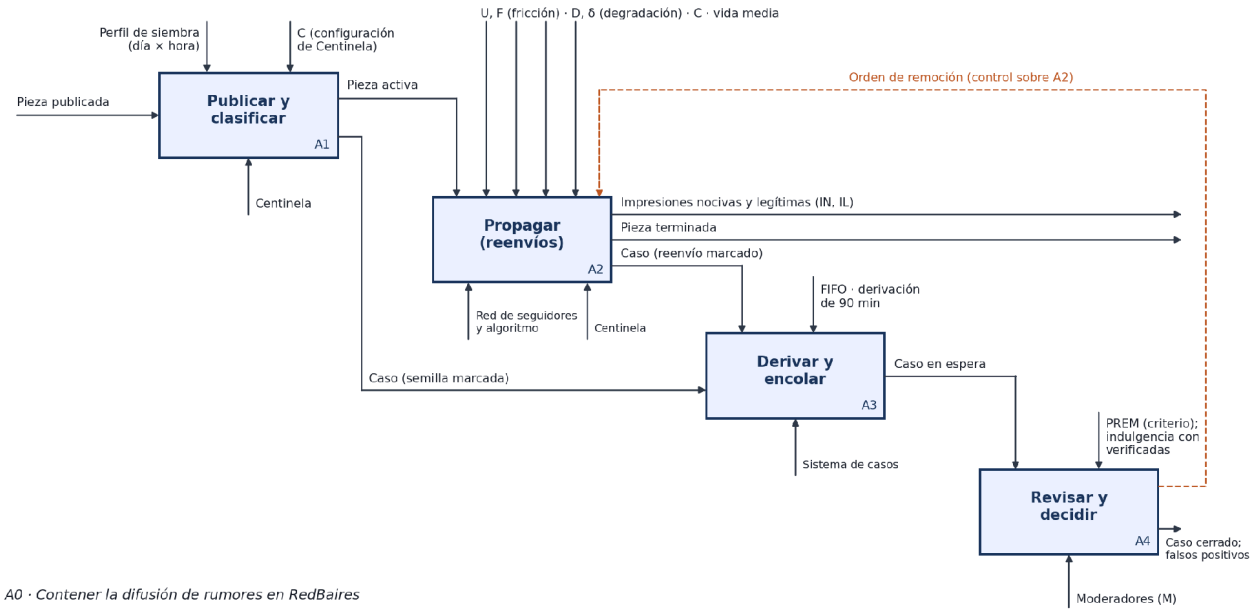


Figura 2. Diagrama IDEF0 de la actividad A0 descompuesta en cuatro actividades (entradas a la izquierda, controles arriba, mecanismos abajo, salidas a la derecha).

El acople es la flecha punteada: la orden de remoción que sale de A4 controla a A2 y corta la cascada. Las VD actúan como controles (C sobre A1 y sobre la evaluación de cada reenvío en A2; U, F, D y δ sobre A2) y M es el mecanismo de A4.

2.7 Eventos destacados y lógicas

La Tabla 6 lista los eventos; la Figura 3 y la Figura 4 muestran su lógica, con las lógicas L1 a L4 que se describen a continuación.

Tabla 6. Eventos del modelo. El fin natural de una cascada y el fin de la réplica son condiciones, no eventos.

Evento	Tipo	Disparador	Estado que cambia
E1 Aparición de una pieza	Exógeno	Llegada de una pieza (Poisson no estacionario)	PA, R_i, acumuladores de IN e IL
E2 Reenvío	Endógeno	Instante del próximo reenvío de una pieza activa	R_i, PA, acumuladores de IN e IL
E3 Ingreso a la fila	Endógeno	Fin de la derivación de un caso (90 min después del primer marcado)	QM, BM, UM
E4 Fin de revisión	Endógeno	Un moderador termina un caso	QM, BM, UM, PA, revisados y falsos positivos (CFP)

Lógicas. L1 (Centinela) marca una aparición con probabilidad P(marca | nociva) = recall y P(marca | legítima) = recall · π · (1 − precisión) / (precisión · (1 − π)), con π la proporción de apariciones nocivas (0,397); con C = 0 da 0,336 y 0,167. L2 (fricción): cuando R_i ≥ U, cada reenvío posterior se bloquea con probabilidad F y, si se bloquea, no genera impresiones ni potencial. L3 (degradación): si la cuenta que reenvía es mega y D la incluye, o si la pieza es C2 y D incluye a las coordinadas, sus impresiones y su potencial se multiplican por (1 − δ). L4 (resultado de la revisión): la pieza se remueve con probabilidad PREM, que depende de si es nociva y baja si la cuenta semilla está verificada; si la cascada ya terminó, la remoción no cambia PA.

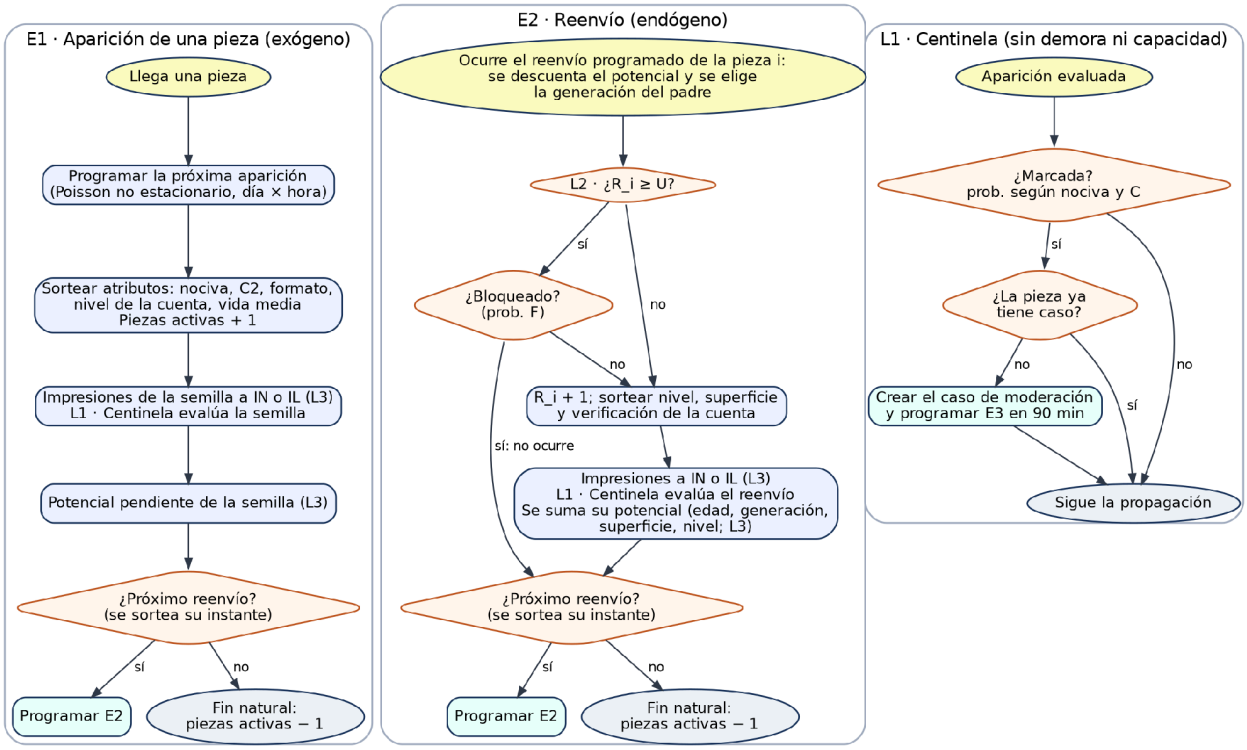


Figura 3. Diagramas lógicos de E1 y E2 y de la lógica de Centinela (L1).

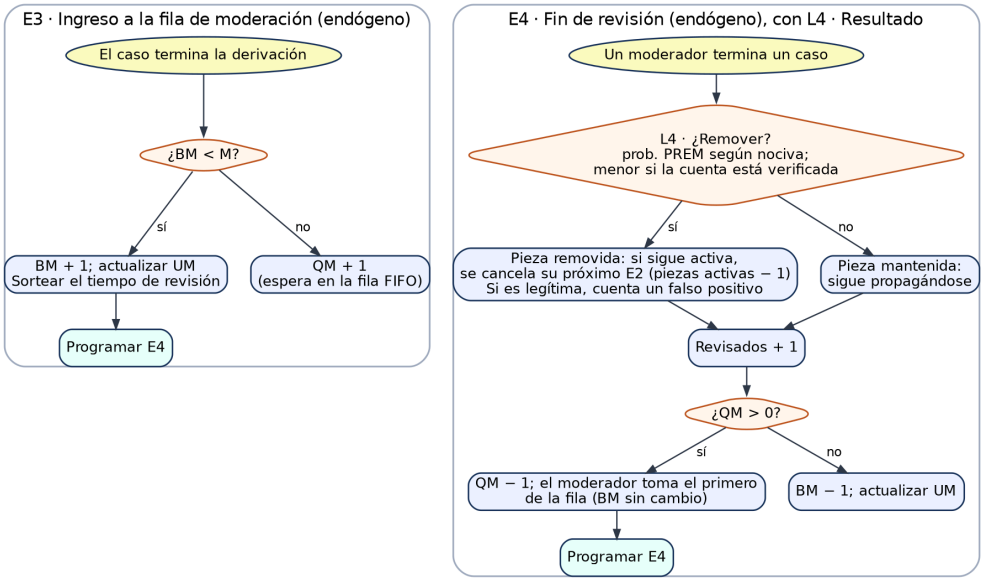


Figura 4. Diagramas lógicos de E3 y E4, con el resultado de la revisión (L4).

Cómo se programa el próximo reenvío. Cada reenvío deja en la pieza un *potencial pendiente*: la cantidad esperada de reenvíos que todavía va a originar, sorteada de una gamma con forma r y media igual a la media de hijos de ese reenvío. Ese potencial se libera en el tiempo en dos fases exponenciales (rápida y diferida) y se descuenta a medida que pasa el tiempo; la pieza lo guarda sumado por generación y por fase. Con esa suma se sortea el instante del próximo reenvío de toda la pieza, y la probabilidad de que no haya ninguno es exp(−potencial total): ese es el fin natural de la cascada. Así cada reenvío genera una cantidad binomial negativa de hijos con el retardo de dos fases ajustado (Anexo A), sin programar un evento por hijo.

Cota de consumo: Cada pieza es una sola entidad con memoria fija (2 fases × 40 generaciones de potencial y una decena de atributos), tiene a lo sumo un evento E2 pendiente y origina a lo sumo un caso de moderación. La memoria de la propagación es proporcional a las piezas activas y no depende del tamaño de las cascadas; por la ley de Little, las piezas activas en promedio son la tasa de siembra por la duración media de una cascada. Los casos en la fila quedan acotados por las piezas sembradas en el horizonte, tampoco por el tamaño de las cascadas. Lo único que crece con una cascada grande es la cantidad de eventos procesados, que es tiempo de cálculo y no memoria (Anexo B).

2.8 Variables aleatorias, Parámetros y relación entre ellos

La Figura 5 muestra qué variable condiciona a cuál. Las fuentes de variabilidad son la llegada de piezas (TES), sus atributos (NOC, C2, FORM, VM, NIVS), la heterogeneidad de quienes reenvían (NIVH, SUP, VER), la cantidad de hijos (H), su ritmo (RET), el alcance (IMP), el error del clasificador (MARCA) y el criterio humano (TREV, PREM). La cuantificación de cada una está en la Tabla 8.

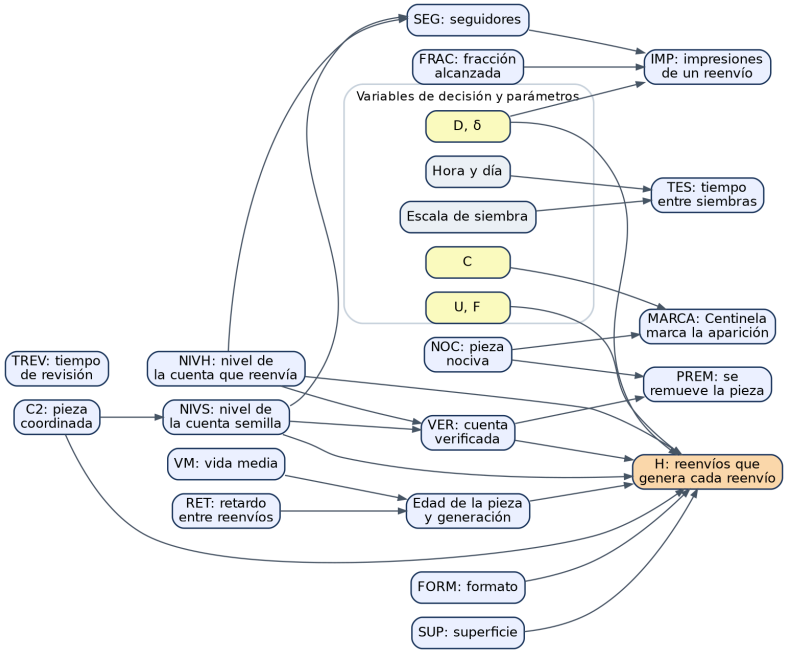


Figura 5. Relación entre variables aleatorias y parámetros. La flecha se lee «condiciona la distribución de».

2.9 Elementos del simulador

La Tabla 7 reúne los elementos que el simulador tiene que representar.

Tabla 7. Elementos del simulador.

Elemento	Contenido
Entidades	Pieza de contenido (entidad principal: llega en E1 y sale al terminar su cascada o ser removida). Caso de moderación (se crea con el primer marcado de la pieza; a lo sumo uno por pieza). El reenvío no es entidad: es el evento E2 de la pieza. La cuenta tampoco: es un atributo sorteado en cada reenvío.
Atributos	Pieza: nociva, C2, formato, nivel y verificación de la cuenta semilla, vida media, R_i, potencial pendiente por generación y fase, instante de la última actualización, estado (activa, terminada, removida) y si ya tiene caso. Caso: pieza asociada, instante de marcado.
Variables	De decisión: M, C, U, F, D, δ. De referencia: IN, IL, CFP. De estado: QM, BM, UM, PA, R_i.
Recursos	Moderadores, con capacidad M por turno y tiempo de revisión TREV. Centinela no es recurso: es la lógica L1.
Colas	Fila de moderación: capacidad ilimitada, disciplina FIFO, sin abandono (un caso se revisa aunque la cascada ya haya terminado, porque la pieza sigue visible).
Actividades	Derivación del caso (90 min fijos), revisión (TREV) y espera hasta el próximo reenvío (resultado del potencial pendiente).
Eventos	E1 Aparición, E2 Reenvío, E3 Ingreso a la fila, E4 Fin de revisión; condiciones de fin natural y de fin de réplica (720 h más el calentamiento).

3 Modelo de Datos

3.1 Tabla diccionario

La Tabla 8 cuantifica cada elemento del modelo conceptual.

Tabla 8. Tabla diccionario del modelo de datos. Las VD y sus rangos están en la Tabla 2.

Variable	Descripción	U.M.	Valor	Relación / expresión	Tipo de función	Parámetros
TES	Tiempo entre siembras	h	no aplica	λ(día, hora) × ESC	Poisson no estacionario	λ de 0,51 a 1,62 piezas/h en la muestra; ESC = 320
NOC	Pieza nociva	0/1	no aplica	no aplica	Bernoulli	p = 0,417
C2	Pieza con señal de coordinación	0/1	no aplica	no aplica	Bernoulli	p = 0,103
NIVS	Nivel de la cuenta semilla	categ.	no aplica	Depende de C2	Discreta	nano/micro/macro/mega: C2 = 0: 55,5 / 7,5 / 15,3 / 21,7 %; C2 = 1: 64,9 / 7,0 / 11,5 / 16,6 %
FORM	Formato de la pieza	categ.	no aplica	no aplica	Discreta	IMG-MACRO 27,3 %, TXT 21,9 %, VID-SHORT 20,3 %, LINK-EXT 14,2 %, SCREENSHOT 11,1 %, POLL 5,2 %
VM	Vida media de la pieza	min	no aplica	no aplica	Lognormal	σ = 0,889; mediana 220,8
NIVH	Nivel de la cuenta que reenvía	categ.	no aplica	Independiente del padre	Discreta	81,5 / 6,7 / 6,2 / 5,6 %
SUP	Superficie del reenvío	categ.	no aplica	no aplica	Discreta	FEED 41,9 %, GROUP 17,7 %, STORY 16,3 %, REPOST 14,0 %, DM 10,0 %
VER	Cuenta verificada	0/1	no aplica	Depende del nivel	Bernoulli	2,4 / 10,8 / 61,1 / 88,9 %
H	Hijos de un reenvío	reenvíos	no aplica	$\mu = \exp(\beta \cdot x) \cdot (1 - \delta)$ si la cuenta está degradada	Binomial negativa	r = 1,25; factores en la Tabla 9
RET	Retardo padre-hijo	min	no aplica	no aplica	Hiperexponencial (2 fases)	w = 0,534; medias 14,3 y 134,8
SEG	Seguidores de quien reenvía	cuentas	no aplica	Depende del nivel	Empírica por nivel	medias 447 / 1.992 / 49.172 / 379.957
FRAC	Fracción de seguidores alcanzada	fracción	no aplica	$IMP = FRAC \cdot SEG \cdot (1 - \delta)$	Weibull	c = 1,336; escala 0,200
MARCA	Centinela marca una aparición	0/1	no aplica	Depende de NOC y C (L1)	Bernoulli	C = 0: 0,336 (nociva), 0,167 (legítima)
DER	Derivación del caso	min	90	Constante	no aplica	Piso de la latencia observada
TREV	Tiempo de revisión	s	no aplica	Supuesto (sin datos)	Exponencial	media 19,6 (costo por caso / costo por hora)
PREM	Remoción tras la revisión	0/1	no aplica	Supuesto (sin datos)	Bernoulli	0,80 nociva, 0,05 legítima; × 0,5 si verificada
ESC	Escala de siembra de la plataforma	veces	320	Calibrada a priori (3.6)	no aplica	8.894 piezas por día
NDEG	Cuentas mega de la plataforma	cuentas	231	Supuesto (cota inferior)	no aplica	Cuentas mega distintas de la muestra
T	Horizonte de una réplica	h	720	Más el primer día descartado	no aplica	Base mensual de Finanzas
Costos	Parámetros de Finanzas	USD	Ver Anexo E	Evaluación económica	no aplica	Valor base y rango de cada uno

3.2 Análisis y cuantificación de variables

Método de recolección. Todos los datos provienen de consultas al registro de RedBaires: no hay mediciones en campo. El archivo de cascadas trae 66.153 filas; sin duplicados quedan 66.021 eventos en 5.000 cascadas, protagonizados por 4.000 cuentas, entre el 01/03/2025 y el 28/08/2025. Los campos se reconstruyeron a partir de su nombre y de sus valores, y cada interpretación se verificó contra la estructura: cada cascada es un árbol con una semilla, todo padre existe, la profundidad del hijo es la del padre más 1 y el contador de reenvíos de cada evento coincide con los hijos reconstruidos. Los defectos (duplicados, mayúsculas mezcladas, fechas centinela 2099, retardos negativos, antigüedades imposibles) se corrigieron o se marcaron como faltantes (Anexo C).

Decisiones de cuantificación. Nociva es la pieza con tema DISARM (41,7 % de las piezas). C2 es la señal de campaña del identificador de hashtags. Los niveles de audiencia se cortan en 1.000, 10.000 y 100.000 seguidores. La muestra está truncada en 500 eventos por cascada (14 cascadas): se excluyen al estimar la propagación y la validación aplica el mismo corte a lo simulado, como corresponde a datos censurados (BANKS, p. 336). Tres cantidades no están en los datos y se fijan como supuestos sujetos a sensibilidad (LAW, p. 375; etapa 5 de la experimentación): el tiempo de revisión, la probabilidad de remoción y la escala de la plataforma, calibrada en la evaluación a priori.

La muestra no registra remociones efectivas. En el 53,0 % de las 2.467 cascadas con algún marcado siguen apareciendo reenvíos después del instante de la primera acción de moderación. Los datos describen la propagación casi sin moderación efectiva: por eso la validación de la sección 3.5 se hace con la propagación sola, y PREM (que el memo define como la remoción que corta la cascada) es un supuesto que se varía en la etapa 5.

3.3 Análisis estadístico

Para cada variable aleatoria se siguió el procedimiento de input modeling (BANKS, p. 331; LAW, p. 279): hipótesis de familia a partir del histograma y de resúmenes como el cociente de Lexis (LAW, p. 322), estimación por máxima verosimilitud, comparación por AIC y prueba de bondad de ajuste. Como los parámetros se estiman con la misma muestra, los valores críticos de Kolmogorov-Smirnov y de chi-cuadrado se obtienen por Montecarlo, ajustando de nuevo cada muestra artificial (LAW, p. 354). Con muestras de decenas de miles, cualquier desvío chico se rechaza; por eso además se comparan los cuantiles de muestras artificiales con los observados. La Figura 6 muestra los ajustes principales; la Tabla 12 y la Tabla 13 (Anexo D) listan todas las candidatas.

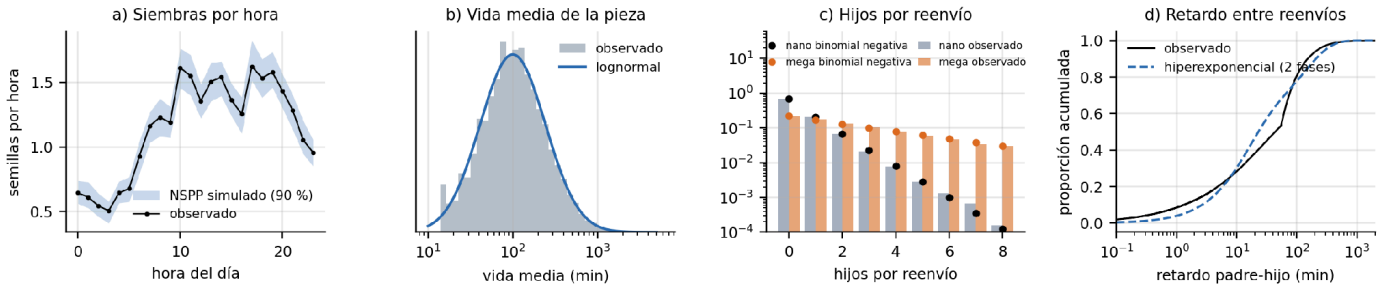


Figura 6. Ajustes principales: (a) siembras por hora contra la banda de Montecarlo del Poisson no estacionario; (b) vida media y lognormal; (c) hijos por reenvío y binomial negativa; (d) retardo entre reenvíos y la hiperexponencial del modelo.

- **Siembras.** 27,8 piezas por día, con perfil horario de 0,51 a 1,62 piezas por hora. El Poisson homogéneo se rechaza (p de Montecarlo < 0,005); el no estacionario por día y hora no (p = 0,14). Se genera por adelgazamiento (LAW, p. 478).
- **Vida media.** Lognormal con σ = 0,889 y mediana 221 min (p = 0,24); va de 15 a 4.994 min.
- **Hijos por reenvío.** El cociente de Lexis va de 1,61 a 6,93: siempre mayor que 1, por lo que la Poisson queda descartada y corresponde la binomial negativa, con r entre 0,73 y 1,30 según el nivel (no rechazada en ningún grupo).
- **Retardo padre-hijo.** Tiene dos poblaciones: la cantidad de retardos por minuto se multiplica por 4,4 al llegar a 55 min (mezcla, LAW, p. 284). La mejor mezcla (Weibull + diferida LN, con 70 % en la componente rápida) igual se rechaza con n grande. El mecanismo de propagación necesita fases exponenciales, así que el modelo usa una hiperexponencial que corta en 55 min: 53,4 % de los retardos con media 14,3 min y el resto con media 134,8 min. Conserva la media total (70,4 min) pero no la forma: su mediana es 23,0 min contra 43,7 observada.
- **Impresiones.** Crecen casi en proporción a los seguidores: la fracción alcanzada es Weibull (c = 1,336, p = 0,71) y no depende del nivel.
- **Centinela y latencia.** Por aparición, precisión 0,570 y recall 0,336 (Finanzas informa 0,72 y 0,63); por pieza, 0,512 y 0,606. La latencia tiene un piso exacto de 90 min y no depende de ningún atributo (R^2 = 0,0002).

3.4 Relación entre variables

Tabla 9. Regresión binomial negativa de los hijos de cada reenvío (dispersión α = 0,80 elegida por verosimilitud perfilada; r = 1,25).

Factor sobre la media de hijos	Factor	IC 95 %
Constante: media de hijos de un reenvío nano, por Mensajes Directos, formato meme	0,448	0,425 a 0,473
Nivel micro (contra nano)	1,640	1,562 a 1,722
Nivel macro	4,789	4,564 a 5,025
Nivel mega	7,172	6,785 a 7,582
Superficie Grupos (contra Mensajes Directos)	2,022	1,915 a 2,135
Superficie Muro	1,652	1,571 a 1,737
Superficie Repost	1,826	1,725 a 1,932

Factor sobre la media de hijos	Factor	IC 95 %
Superficie Historias	1,359	1,284 a 1,438
Formato video corto (contra meme)	1,096	1,064 a 1,129
Formato enlace externo	0,574	0,538 a 0,611
Formato texto	0,676	0,647 a 0,708
Formato captura de pantalla	0,817	0,778 a 0,858
Formato encuesta	0,749	0,698 a 0,803
Pieza C2	1,795	1,740 a 1,851
Cuenta verificada	1,127	1,074 a 1,183
Es la semilla	1,136	1,089 a 1,185
Por cada vida media de edad	0,508	0,494 a 0,522
Por cada generación	0,900	0,893 a 0,907
Pieza nociva	0,988	0,963 a 1,014

La media de hijos se modela como $\mu = \exp(\beta \cdot x)$, donde x reúne nivel, superficie, formato, C2, verificación, si es la semilla, edad relativa y generación: cada factor de la Tabla 9 la multiplica. Cuatro relaciones definen el modelo. Primera, la vida media del memo es la del ritmo de reenvíos: el coeficiente de la edad relativa es −0,678 (IC 95 %: −0,706 a −0,650), compatible con $-\ln 2 = -0{,}693$. Segunda, cada generación multiplica la media por 0,900 con independencia de la edad (mejora el AIC en 721). Tercera, la audiencia actúa por nivel y de forma sublineal, como dice el memo: mega multiplica por 7,17 con cientos de veces más seguidores. Cuarta, el contenido nocivo no se reenvía distinto del legítimo (S3). Además, el nivel de quien reenvía no depende del de su padre (chi-cuadrado 12,2, p de permutación 0,21), la verificación depende del nivel (2,4 / 10,8 / 61,1 / 88,9 %) y las piezas C2 nacen más a menudo en cuentas chicas pero tienen cascadas más grandes (tamaño medio 42,8 contra 9,8).

3.5 Verificación integral contra los datos

La Figura 7 contrasta el mecanismo completo con los datos.

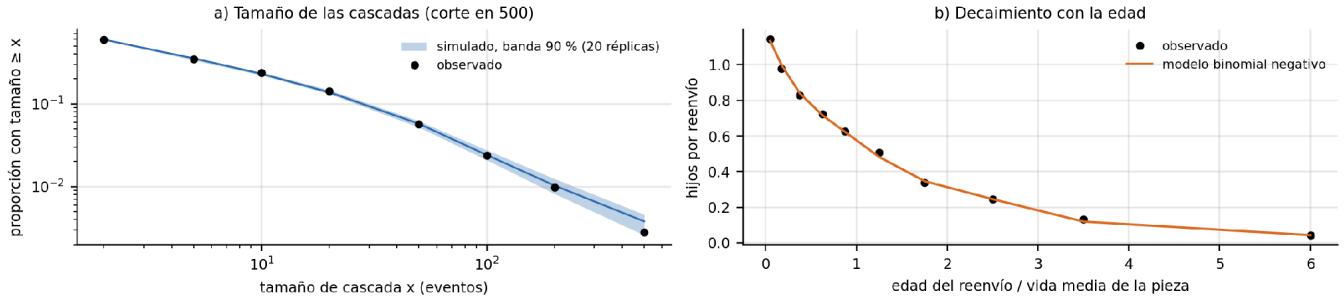


Figura 7. (a) Tamaños de cascada observados contra la banda de 20 réplicas del mecanismo del modelo, con el mismo corte en 500; (b) media de hijos según la edad, observada y del modelo.

La condición de aceptación del caso exige cascadas con forma y dispersión parecidas a las observadas. Se generaron 20 muestras artificiales de 5.000 cascadas con el mecanismo de la sección 2.7 y las distribuciones de la Tabla 8, sin moderación. La curva de tamaños observada cae dentro de la banda del 90 % en 8 de sus 8 puntos (con 20 réplicas la banda es aproximada). El tamaño medio simulado es 13,63 contra 13,20 observado; el percentil 90 de la duración, 9,5 h contra 8,9 h, y el percentil 99 de la profundidad, 10 en ambos. La duración mediana queda corta (0,54 h contra 0,94 h) porque la hiperexponencial pone más retardos muy cortos que la mezcla observada. No afecta el tamaño, pero adelanta los reenvíos respecto del piso de 90 minutos de la moderación, de modo que el efecto de moderar queda estimado por defecto. La fase diferida puede llevar una etapa previa de espera sin romper la cota de consumo.

3.6 Evaluación a priori

Tamaño de las cascadas según m. Simplificando a un proceso de ramificación con media $m_0 = 2{,}346$ hijos para la semilla y $m = 0{,}784$ para cada reenvío, el tamaño esperado es $1 + m_0 / (1 - m) = 11{,}84$ eventos. Con las medias de la propia muestra esto es un chequeo de consistencia (coincide con el tamaño medio de las 4.986 cascadas completas; el 13,20 observado incluye las truncadas). Lo que la fórmula anticipa es la sensibilidad: con $m = 0{,}95$ el tamaño pasa a 47,9, y cerca de 1 una diferencia chica en m cambia mucho el tamaño, que es la idea del escenario pesimista. Con fricción desde

el primer reenvío (U = 0, fuera del rango de la VD, como cota optimista), las medias se multiplican por (1 − F): F = 0,25 da 5,27; F = 0,50 da 2,93; F = 0,75 da 1,73.

Fila de moderación. Si el costo por caso (0,12 USD) se interpreta como tiempo de moderador a 22 USD por hora, la revisión dura 19,6 s (μ = 3,056 casos/min). La espera media por encima del piso es W = 148,2 min; con M/M/1, W = 1 / (μ − λ) (ANDERSON, cap. 15; BANKS, p. 247) despeja λ = 3,049 casos/min y ρ = 0,9978: la fila actual está al borde de la saturación. Esos 4.390 casos diarios contra 13,7 piezas marcadas por día en la muestra dan la escala ESC = 320. Con M/M/c, un segundo moderador casi elimina la espera. Es una estimación gruesa: en M/M/1 el tiempo en el sistema es exponencial, y la latencia observada no lo es (su mediana sería 193 min y es 140).

Tabla 10. Fila de moderación como M/M/c con λ y μ calibrados (ANDERSON, §15.3).

M	ρ	Lq (casos)	Wq (min)
1	0,998	450,740	147,841
2	0,499	0,331	0,108
3	0,333	0,045	0,015

Alcance máximo de la moderación. El 56,5 % de las cascadas terminan antes de los 90 minutos. En los datos, solo el 42,1 % de las impresiones nocivas ocurre más de 90 minutos después del primer marcado de su pieza: aun con espera nula en la fila, la moderación no puede evitar más que esa fracción, y con PREM = 0,80 la reducción de IN queda cerca del 34 %. El resto solo lo alcanzan la fricción y la degradación, que actúan desde el primer reenvío.

4 Bibliografía, referencias y Anexos

4.1 Bibliografía

Anderson, D. R.; Sweeney, D. J.; Williams, T. A.; Camm, J. D.; Martin, K. *Métodos cuantitativos para los negocios*, 11.ª ed., Cengage Learning, 2011, cap. 15: Modelos de líneas de espera. [ANDERSON]

Banks, J.; Carson, J. S.; Nelson, B. L.; Nicol, D. M. *Discrete-Event System Simulation*, 5.ª ed., Pearson, 2013. [BANKS]

Law, A. M. *Simulation Modeling and Analysis*, 5.ª ed., McGraw-Hill, 2014. [LAW]

4.2 Referencias

RedBaires S.A., Dirección de Confianza y Seguridad. Memorándum interno «Dinámica de difusión de rumores en la plataforma y evaluación de contramedidas», 15/09/2026 (consigna del TP3).

Archivos de datos: muestra_cascadas_REDBAIRES.csv y parametros_y_costos.csv (TP3_datos.zip).

Cuaderno de análisis TP3_modelo_de_datos.ipynb: limpieza, ajustes, relaciones y validación (Anexo F).

4.3 Descripción teórica de temas que exceden el curso

Tres herramientas exceden el curso. El mecanismo de propagación es un proceso de ramificación en el que cada reenvío deja un potencial que se libera en dos fases exponenciales: así la pieza guarda una suma y no un evento por hijo. La binomial negativa surge como mezcla de Poisson y gamma, y explica la sobredispersión de los hijos. La prueba de Kolmogorov-Smirnov con valores críticos por Montecarlo corrige el uso de parámetros estimados. El Anexo A desarrolla las tres.

Anexos

Anexo A. Descripción teórica

Proceso de ramificación. Si cada reenvío origina en promedio m reenvíos independientes, el tamaño esperado de la cascada es finito solo si m < 1, y vale 1 + m_0 / (1 − m) cuando la semilla tiene media m_0. Es el «factor de multiplicación» del memo.

Binomial negativa. Si la cantidad de hijos es Poisson con una media que varía de un reenvío a otro según una gamma de forma r, la cantidad resultante es binomial negativa con parámetro r y varianza μ + μ²/r, mayor que la media (cociente de Lexis mayor que 1). Con r = 1 es la geométrica (LAW, p. 310–311).

Potencial pendiente. Cada reenvío j ocurrido en el instante t_j aporta una intensidad $J_j \cdot g(t - t_j)$, con $J_j \sim$ gamma(r, μ_j / r) y g la densidad del retardo. Si g es una mezcla de dos exponenciales con pesos w_k y tasas κ_k, la intensidad de la pieza es la suma de $A_k \cdot \kappa_k$, donde A_k es el potencial pendiente de la fase k, que decae como $\exp(-\kappa_k \cdot s)$ entre eventos y crece en $w_k \cdot J_j$ con cada reenvío. El próximo reenvío de cada fase se sortea por inversión: con E ~ exponencial(1), $s = -\ln(1 - E / A_k) / \kappa_k$ si $E < A_k$, y no hay más reenvíos de esa fase si $E \geq A_k$; el próximo de la pieza es el menor de las dos fases. La cantidad total de hijos de j es Poisson con media J_j, es decir, binomial negativa con media μ_j, y sus retardos siguen g. Guardar el potencial por generación permite aplicar el factor de generación al hijo, eligiendo la generación del padre en proporción a su potencial.

Kolmogorov-Smirnov con parámetros estimados. Las tablas clásicas del estadístico D suponen parámetros conocidos. Si se estiman de la muestra, el valor crítico se obtiene generando muestras de la distribución ajustada, reajustando cada una y recalculando D (LAW, p. 354; BANKS, p. 361). Para las siembras se aplica a los tiempos reescalados por la intensidad acumulada, que bajo un Poisson no estacionario son exponenciales de media 1.

Anexo B. Cota de consumo

Memoria por pieza: 2 × 40 potenciales, R_i, el instante de la última actualización y unos diez atributos fijos, cualquiera sea el tamaño de su cascada (las generaciones mayores a 39 se acumulan en la última; en la muestra el percentil 99 de la profundidad es 10). Eventos pendientes por pieza: uno de E2 y, si tiene caso, uno de E3 o de E4. Entidades: piezas activas más casos abiertos; como hay a lo sumo un caso por pieza sembrada, los casos quedan acotados por las piezas que aparecen en el horizonte (si ρ ≥ 1 la fila crece durante el mes, pero esa es una propiedad de la configuración evaluada, no del tamaño de las cascadas). En el escenario pesimista el factor de multiplicación puede superar 1 al comienzo, pero la media de hijos cae a la mitad con cada vida media de edad, de modo que toda cascada se vuelve subcrítica en tiempo finito y la cantidad de piezas activas sigue acotada por la tasa de siembra por la duración de una cascada (ley de Little).

Anexo C. Limpieza de los datos

Tabla 11. Defectos encontrados en el archivo de cascadas y su tratamiento.

Defecto	Casos	Tratamiento
Filas duplicadas exactas	132	Se eliminan (repiten event_id y todos los campos)
content_type_code con mayúsculas distintas de la forma habitual	4.644	Se normaliza a mayúscula
platform_surface_code con mayúsculas distintas de la forma habitual	4.629	Se normaliza a mayúscula
language_code con mayúsculas distintas de la forma habitual	4.551	Se normaliza a mayúscula
language_code ES-AR (variante de ES)	6.263	Se unifica como ES
Fecha centinela 2099-01-01	39	Reenvío: fecha del padre + retardo. Semilla: fecha de un hijo menos su retardo
Semilla con fecha centinela y sin hijos	2	Fecha irrecuperable: queda faltante (cascada de un solo evento)
Retardo padre-hijo negativo	39	Se recalcula desde las fechas de padre e hijo
Antigüedad = 6.000 días (centinela)	223	Faltante
Antigüedad mayor a 4622 días (anterior a 2013)	271	Faltante
Seguidores = 0	52	Faltante (el mínimo del resto es 300)
dwell_time_sec negativo	66	Faltante
Impresiones mayores que seguidores	1	Se conservan: posible alcance por recomendación fuera de seguidores
Faltantes en impressions	625	Se dejan faltantes; solo se imputan si el modelo usa el campo

Defecto	Casos	Tratamiento
Faltantes en comments	936	Se dejan faltantes; solo se imputan si el modelo usa el campo
Faltantes en dwell_time_sec	2.005	Se dejan faltantes; solo se imputan si el modelo usa el campo
Faltantes en content_half_life_min	666	Se dejan faltantes; solo se imputan si el modelo usa el campo
Faltantes en sentiment_score	1.344	Se dejan faltantes; solo se imputan si el modelo usa el campo
Faltantes en device_fingerprint_code	1.324	Se dejan faltantes; solo se imputan si el modelo usa el campo
Cascadas truncadas en 500 eventos	14	Se excluyen al estimar la propagación; el mismo corte se aplica al validar

Anexo D. Ajustes de distribuciones

Tabla 12. Candidatas para las variables continuas, ordenadas por AIC. El estadístico KS y su crítico se calculan sobre una submuestra; p MC es el p de Montecarlo.

Variable	Candidata	Parámetros (MLE)	AIC	KS	KS crítico MC	p MC
Vida media de la pieza	Lognormal	s=0,8891; loc=0; escala=220,8	66.322,5	0,0185	0,0228	0,245
	Gamma	a=1,397; loc=0; escala=235,5	66.977,7	0,0763	0,0227	0,000
	Weibull	c=1,118; loc=0; escala=345	67.172,2	0,0718	0,0237	0,000
	Exponencial	loc=0; escala=329	67.284,3	0,1072	0,0280	0,000
Retardo padre-hijo (familias simples)	Weibull	c=0,6733; loc=0; escala=53,3	547.461,1	0,1069	0,0240	0,000
	Gamma	a=0,5433; loc=0; escala=129,6	548.392,4	0,0899	0,0245	0,000
	Lognormal	s=1,983; loc=0; escala=22,21	560.219,7	0,1497	0,0240	0,000
	Exponencial	loc=0; escala=70,44	565.682,0	0,1403	0,0287	0,000
Retardo padre-hijo (mezclas)	Weibull + diferida LN	w=0,701; rápida Weibull(0,619; 29,7); diferida 55 + LN(mu=3,236; sigma=1,522)	538.379,0	0,0223	0,0169	0,000
	Gamma + diferida LN	w=0,703; rápida Gamma(0,521; 74,5); diferida 55 + LN(mu=3,342; sigma=1,571)	538.804,0	0,0283	0,0209	0,000
	Lognormal + diferida LN	w=0,671; rápida Lognormal(2,06; 11); diferida 55 + LN(mu=3,143; sigma=1,384)	541.917,9	0,0334	0,0195	0,000
	Exponencial + diferida LN	w=0,555; rápida Exponencial(16,4); diferida 55 + LN(mu=3,459; sigma=1,461)	544.891,2	0,0719	0,0183	0,000
Fracción de seguidores alcanzada	Weibull	c=1,336; loc=0; escala=0,2	−98.364,6	0,0137	0,0238	0,710
	Beta	a=1,312; b=5,796; loc=0; escala=1	−98.326,3	0,0209	0,0239	0,105
	Gamma	a=1,568; loc=0; escala=0,1173	−97.666,1	0,0256	0,0241	0,025
	Lognormal	s=0,9689; loc=0; escala=0,1294	−85.967,4	0,0791	0,0238	0,000
Latencia de moderación (observada)	Lognormal	s=1,575; loc=89,99; escala=45,39	175.716,8	0,0392	0,0224	0,000
	Weibull	c=0,6549; loc=89,99; escala=97,19	177.226,3	0,0573	0,0221	0,000
	Gamma	a=0,5318; loc=89,99; escala=278,6	179.921,8	0,1172	0,0243	0,000
	Exponencial	loc=89,99; escala=148,2	185.293,2	0,2460	0,0279	0,000

Tabla 13. Hijos por evento según tipo y nivel de audiencia (chi-cuadrado con crítico de Montecarlo).

Evento	Nivel	n	Media	Lexis	Candidata	Parámetros	p MC
reenvío	nano	44.025	0,466	1,61	Binomial negativa	r=0,816; p=0,6362	0,695
reenvío	nano	44.025	0,466	1,61	Geométrica	p=0,6819	0,660
reenvío	nano	44.025	0,466	1,61	Poisson	media=0,466	0,000
reenvío	micro	3.605	0,774	2,11	Binomial negativa	r=0,727; p=0,4844	0,620
reenvío	micro	3.605	0,774	2,11	Geométrica	p=0,5638	0,000
reenvío	micro	3.605	0,774	2,11	Poisson	media=0,774	0,000
reenvío	macro	3.349	2,366	3,84	Binomial negativa	r=0,903; p=0,2763	0,540
reenvío	macro	3.349	2,366	3,84	Geométrica	p=0,2971	0,170
reenvío	macro	3.349	2,366	3,84	Poisson	media=2,366	0,000
reenvío	mega	3.014	3,668	5,16	Binomial negativa	r=0,935; p=0,2031	0,195
reenvío	mega	3.014	3,668	5,16	Geométrica	p=0,2142	0,425
reenvío	mega	3.014	3,668	5,16	Poisson	media=3,668	0,000
semilla	nano	2.818	0,803	1,92	Geométrica	p=0,5545	0,930
semilla	nano	2.818	0,803	1,92	Binomial negativa	r=0,912; p=0,5315	0,530
semilla	nano	2.818	0,803	1,92	Poisson	media=0,803	0,000
semilla	micro	371	1,189	1,77	Binomial negativa	r=1,300; p=0,5224	0,320
semilla	micro	371	1,189	1,77	Geométrica	p=0,4569	0,300
semilla	micro	371	1,189	1,77	Poisson	media=1,189	0,000
semilla	macro	739	3,901	4,51	Geométrica	p=0,2040	0,520

Evento	Nivel	n	Media	Lexis	Candidata	Parámetros	p MC
semilla	macro	739	3,901	4,51	Binomial negativa	r=1,105; p=0,2207	0,570
semilla	macro	739	3,901	4,51	Poisson	media=3,901	0,000
semilla	mega	1.054	5,790	6,93	Geométrica	p=0,1473	0,800
semilla	mega	1.054	5,790	6,93	Binomial negativa	r=1,030; p=0,1510	0,770
semilla	mega	1.054	5,790	6,93	Poisson	media=5,790	0,000

Anexo E. Parámetros de Finanzas

Tabla 14. Parámetros económicos de parametros_y_costos.csv.

Parámetro (nombre en el archivo)	Base	Rango	Unidad
valor_engagement_por_impresion	0,0009	0,0003 a 0,0030	USD/impresión
costo_moderador_por_hora	22	14 a 45	USD/hora
moderadores_por_turno	1	1 a 12	cantidad
horas_operativas_mes	720	672 a 744	horas/mes
costo_revision_por_item_flag	0,12	0,05 a 0,60	USD/ítem
capex_clasificador_ml	250.000	80.000 a 900.000	USD
opex_anual_clasificador	60.000	20.000 a 180.000	USD/año
vida_util_clasificador_years	4	2 a 8	años
discount_rate	0,10	0,06 a 0,18	fracción
precision_clasificador	0,72	0,50 a 0,95	fracción
recall_clasificador	0,63	0,30 a 0,90	fracción
costo_reputacional_por_falso_positivo	1,50	0,20 a 10	USD/ítem
costo_social_por_impresion_nociva	0,0040	0,0010 a 0,05	USD/impresión
reduccion_alcance_rate_limit	0	0 a 0,90	fracción
umbral_reenvios_rate_limit	5	1 a 20	cantidad
perdida_engagement_por_rate_limit	0,15	0,02 a 0,50	fracción
costo_degradar_influencer_por_dia	120	20 a 600	USD/día
latencia_objetivo_moderacion_min	120	30 a 720	min
valor_marca_por_usuario_activo	3,20	1 a 12	USD/usuario·mes
tasa_churn_por_exposicion_nociva	0,0006	0,0001 a 0,0040	fracción

Anexo F. Reproducibilidad

Todas las cifras de este informe se calculan con el cuaderno TP3_modelo_de_datos.ipynb (semilla 20260929), la validación del mecanismo de propagación usa la semilla 20261001 y 20 réplicas.